BÁO CÁO DỰ ÁN DATA ANALYSIS

Brazilian E-Commerce Dataset – Olist

1. Giới thiệu dự án (Project Overview)

1.1. Tổng quan

Dự án sử dụng bộ dữ liệu Brazilian E-Commerce Public Dataset của Olist, một nền tảng thương mại điện tử tại Brazil. Bộ dữ liệu cung cấp thông tin về hoạt động kinh doanh trực tuyến trong giai đoạn 2016–2018.

Dataset bao gồm 9 bảng dữ liệu CSV, mô tả nhiều khía cạnh của hoạt động thương mại điện tử như khách hàng, đơn hàng, sản phẩm, thanh toán, đánh giá, người bán và thông tin địa lý.

Mục tiêu của dự án là thực hiện quy trình phân tích dữ liệu từ bước tìm hiểu dữ liệu, làm sạch dữ liệu, phân tích khám phá (EDA), tìm kiếm Business Insights và xây dựng nền tảng cho các bước phân tích chuyên sâu tiếp theo.

1.2. Mục tiêu dự án

- Tìm hiểu cấu trúc và đặc điểm của bộ dữ liệu.
- Kiểm tra chất lượng dữ liệu và xử lý các vấn đề về dữ liệu thiếu, dữ liệu trùng lặp và kiểu dữ liệu.
- Khám phá xu hướng doanh thu và hiệu suất kinh doanh.
- Phân tích sản phẩm, khách hàng và trải nghiệm mua sắm.
- Đưa ra những nhận xét và đề xuất dựa trên dữ liệu.

1.3. Công cụ sử dụng

- Python
- Pandas, NumPy
- Matplotlib, Seaborn
- Jupyter Notebook

2. Data Understanding – Tìm hiểu dữ liệu

2.1. Tổng quan bộ dữ liệu

Bộ dữ liệu Olist bao gồm 9 bảng:

Bảng dữ liệu	Nội dung
customers	Thông tin khách hàng
orders	Thông tin đơn hàng
order_items	Chi tiết sản phẩm trong đơn hàng
products	Thông tin sản phẩm
order_payments	Thông tin thanh toán
order_reviews	Đánh giá của khách hàng
sellers	Thông tin người bán
geolocation	Dữ liệu vị trí địa lý
product_category_name_translation	Dịch tên danh mục sản phẩm

Các bảng có mối quan hệ với nhau thông qua những khóa như `order_id`, `customer_id`, `product_id` và `seller_id`.

2.2. Kiểm tra cấu trúc dữ liệu

Trong giai đoạn này, các thao tác kiểm tra được thực hiện:

- Xác định số lượng dòng và cột của từng bảng.
- Kiểm tra kiểu dữ liệu của các thuộc tính bằng `dtype`.
- Kiểm tra số lượng giá trị thiếu bằng `isnull()`.
- Kiểm tra dữ liệu trùng lặp bằng `duplicated()`.
- Khảo sát các giá trị phân loại như `order_status`, `payment_type` và `review_score`.
- Xác định các cột thời gian và các khóa có khả năng đóng vai trò Primary Key, Foreign Key.

2.3. Kết quả tìm hiểu dữ liệu

Qua quá trình khảo sát, dữ liệu được xác định có cấu trúc quan hệ gồm nhiều bảng liên kết với nhau. Một số bảng chứa dữ liệu thời gian, dữ liệu phân loại, dữ liệu định lượng và thông tin định danh.

Đặc biệt, bảng `geolocation` có số lượng bản ghi lớn, với 1.000.163 dòng và 261.831 dòng trùng lặp hoàn toàn.

Những kết quả này được sử dụng làm cơ sở để xây dựng kế hoạch làm sạch dữ liệu ở giai đoạn tiếp theo.

3. Data Cleaning – Làm sạch dữ liệu

3.1. Tổ chức và nạp dữ liệu

Các file CSV được tổ chức thành hai thư mục:

- `data/raw`: lưu trữ dữ liệu gốc.
- `data/processed`: lưu trữ dữ liệu sau khi xử lý.

Sử dụng Pandas để đọc các bảng dữ liệu vào DataFrame, phục vụ cho quá trình kiểm tra và làm sạch.

3.2. Xử lý giá trị thiếu (Missing Values)

Sau khi kiểm tra, một số thuộc tính có tỷ lệ dữ liệu thiếu đáng chú ý:

Bảng	Thuộc tính	Số lượng thiếu
order_reviews	review_comment_title	87.656
order_reviews	review_comment_message	58.247
orders	order_delivered_customer_date	2.965
orders	order_delivered_carrier_date	1.783
orders	order_approved_at	160
products	product_category_name	610
products	product_weight_g	2
products	product_length_cm	2
products	product_height_cm	2
products	product_width_cm	2

Phương pháp xử lý:

- Đối với `review_comment_title` và `review_comment_message`: giữ nguyên giá trị thiếu vì khách hàng có thể gửi đánh giá mà không viết bình luận.
- Đối với các cột thời gian giao hàng: giữ nguyên giá trị thiếu vì không phải tất cả đơn hàng đều hoàn tất giao hàng.
- Đối với `product_category_name` và các thuộc tính mô tả sản phẩm: giữ nguyên giá trị thiếu để tránh tự tạo ra thông tin không có trong dữ liệu gốc.

- Đối với các thuộc tính trọng lượng và kích thước: giữ nguyên giá trị thiếu và xem xét riêng khi thực hiện những phân tích cần thông tin này.

Không áp dụng phương pháp điền trung bình hoặc trung vị một cách máy móc cho các thuộc tính trên vì việc này có thể làm sai lệch ý nghĩa dữ liệu.

3.3. Xử lý dữ liệu trùng lặp (Duplicate Records)

Qua kiểm tra, bảng `geolocation` có:

- Tổng số bản ghi ban đầu: 1.000.163.
- Số bản ghi trùng lặp hoàn toàn: 261.831.
- Số bản ghi sau khi loại bỏ trùng lặp: 738.332.

Sử dụng phương thức `drop_duplicates()` để loại bỏ những dòng có toàn bộ giá trị thuộc tính giống nhau.

Các giá trị ZIP code hoặc tọa độ xuất hiện nhiều lần không bị loại bỏ chỉ vì trùng lặp một thuộc tính, bởi chúng có thể đại diện cho nhiều vị trí hoặc bản ghi hợp lệ.

3.4. Chuyển đổi kiểu dữ liệu (Data Type Conversion)

Các cột thời gian được chuyển sang kiểu datetime bằng `pd.to_datetime()`.

Các thuộc tính thời gian được xử lý bao gồm:

- `order_purchase_timestamp`
- `order_approved_at`
- `order_delivered_carrier_date`
- `order_delivered_customer_date`
- `order_estimated_delivery_date`
- `review_creation_date`
- `review_answer_timestamp`

Sử dụng `errors='coerce'` để chuyển những giá trị thời gian không hợp lệ thành `NaT`.

Việc chuyển đổi này giúp thuận tiện cho việc trích xuất năm, tháng, ngày và tính toán khoảng thời gian trong các bước phân tích tiếp theo.

3.5. Kiểm tra tính hợp lệ của dữ liệu (Data Validation)

Các bước kiểm tra được xây dựng nhằm phát hiện:

- Ngày duyệt đơn hàng trước ngày đặt hàng.
- Ngày bàn giao cho đơn vị vận chuyển trước ngày đặt hàng.
- Ngày giao hàng trước ngày đặt hàng.
- Giá sản phẩm hoặc phí vận chuyển âm.
- Điểm đánh giá nằm ngoài khoảng từ 1 đến 5.
- Trọng lượng và kích thước sản phẩm có giá trị không hợp lệ.

Những trường hợp bất thường cần được kiểm tra theo logic nghiệp vụ trước khi quyết định loại bỏ hoặc điều chỉnh.

3.6. Lưu dữ liệu sau khi xử lý

Sau khi thực hiện các bước làm sạch, dữ liệu được lưu vào thư mục `data/processed` dưới định dạng CSV.

Việc lưu dữ liệu riêng biệt giúp bảo toàn dữ liệu gốc và tạo nguồn dữ liệu nhất quán cho các giai đoạn phân tích tiếp theo.

4. Exploratory Data Analysis (EDA) – Phân tích khám phá dữ liệu

4.1. Sales Analysis – Phân tích doanh thu

Mục tiêu

Phân tích sự thay đổi doanh thu sản phẩm theo thời gian nhằm xác định xu hướng tăng trưởng và những giai đoạn có doanh thu nổi bật.

Phương pháp thực hiện

Kết hợp bảng `order_items` với `orders` thông qua `order_id` để lấy thời gian đặt hàng.

Sau đó:

- Trích xuất tháng từ `order_purchase_timestamp`.
- Nhóm dữ liệu theo tháng bằng `groupby()`.
- Tính tổng `price` của các sản phẩm trong từng tháng.
- Trực quan hóa bằng biểu đồ đường (Line Chart).

Doanh thu trong phần phân tích này được định nghĩa là tổng giá trị sản phẩm (`price`), chưa bao gồm phí vận chuyển (`freight_value`).

Kết quả phân tích

Dữ liệu ghi nhận 24 tháng có bản ghi doanh thu, từ tháng 09/2016 đến tháng 09/2018.

Một số kết quả đáng chú ý:

- Doanh thu nhìn chung tăng trong năm 2017.
- Tháng 11/2017 ghi nhận doanh thu cao nhất, đạt khoảng 1.010.271,37 BRL.
- Trong giai đoạn tháng 01–05/2018, doanh thu duy trì ở mức tương đối cao.
- Tháng 09/2016, 12/2016 và 09/2018 có doanh thu thấp bất thường so với các tháng khác.

Business Insights sơ bộ

Hoạt động kinh doanh của Olist có xu hướng mở rộng trong năm 2017 và duy trì mức doanh thu sản phẩm cao trong nửa đầu năm 2018.

Tuy nhiên, các tháng đầu và cuối phạm vi dữ liệu có thể chỉ phản ánh một phần thời gian quan sát. Vì vậy, cần thận trọng khi so sánh trực tiếp những tháng này với các tháng đầy đủ khác.

4.2. Product Analysis – Phân tích danh mục sản phẩm

Mục tiêu

Xác định những danh mục sản phẩm đóng góp doanh thu lớn nhất và so sánh doanh thu giữa các danh mục.

Phương pháp thực hiện

Kết hợp ba bảng:

- `order_items`: thông tin sản phẩm trong đơn hàng và giá bán.
- `products`: thông tin danh mục sản phẩm.
- `product_category_name_translation`: bản dịch tên danh mục sang tiếng Anh.

Sau đó nhóm dữ liệu theo danh mục sản phẩm, tính tổng `price` và đếm số dòng sản phẩm được ghi nhận.

Kết quả phân tích

Top 10 danh mục có doanh thu cao nhất:

Danh mục	Doanh thu (BRL)
Health & Beauty	1.258.681,34
Watches & Gifts	1.205.005,68
Bed, Bath & Table	1.036.988,68
Sports & Leisure	988.048,97
Computers & Accessories	911.954,32
Furniture & Decor	729.762,49
Cool Stuff	635.290,85
Housewares	632.248,66
Auto	592.720,11

Danh mục	Doanh thu (BRL)
Garden Tools	485.256,46

Business Insights sơ bộ

- Health & Beauty là danh mục có doanh thu cao nhất trong Top 10, đạt khoảng 1,26 triệu BRL.
- Watches & Gifts đứng thứ hai với khoảng 1,21 triệu BRL.
- Bed, Bath & Table có số dòng sản phẩm được ghi nhận cao nhất trong Top 10, với 11.115 dòng.
- Số dòng sản phẩm bán ra và tổng doanh thu không có thứ hạng giống nhau giữa các danh mục.

Điều này cho thấy doanh thu của một danh mục không chỉ phụ thuộc vào số dòng sản phẩm được bán mà còn liên quan đến mức giá của các sản phẩm.

Lưu ý: Số liệu đếm ở đây là số dòng sản phẩm trong `order_items`, không phải số lượng đơn hàng duy nhất.

5. Tổng kết tiến độ

Tính đến thời điểm hiện tại, dự án đã hoàn thành các công việc sau:

Giai đoạn	Nội dung	Trạng thái
Data Understanding	Khảo sát 9 bảng dữ liệu	**Hoàn thành**
Data Understanding	Kiểm tra kiểu dữ liệu, missing, duplicate	**Hoàn thành**
Data Cleaning	Phân tích và xử lý missing values	**Đã thực hiện**
Data Cleaning	Loại bỏ bản ghi trùng lặp hoàn toàn trong geolocation	**Đã thực hiện**
Data Cleaning	Chuyển đổi kiểu dữ liệu thời gian	**Đã thực hiện**
Data Cleaning	Kiểm tra tính hợp lệ	**Đã xây dựng các bước kiểm tra**
Data Cleaning	Lưu dữ liệu processed	**Đã thực hiện theo quy trình**
EDA	Phân tích doanh thu theo tháng	**Hoàn thành**

7. Kết luận

Dự án đã hoàn thành giai đoạn tìm hiểu dữ liệu, triển khai các bước làm sạch cơ bản và bắt đầu phân tích khám phá dữ liệu.

Thông qua việc phân tích doanh thu theo thời gian và theo danh mục sản phẩm, dự án đã bước đầu xác định được xu hướng doanh thu cũng như những danh mục đóng góp doanh thu nổi bật.

Các kết quả hiện tại là nền tảng để tiếp tục phân tích hành vi khách hàng, hiệu quả vận hành và trải nghiệm mua sắm, từ đó xây dựng những nhận định có giá trị hỗ trợ hoạt động kinh doanh thương mại điện tử.